

# 기초 선형대수

## (Spectral Property – 고유값/고유벡터/행렬의 인수분해)

윤정훈

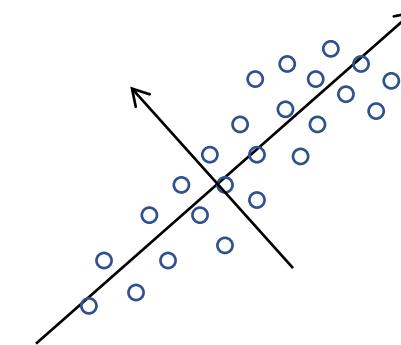
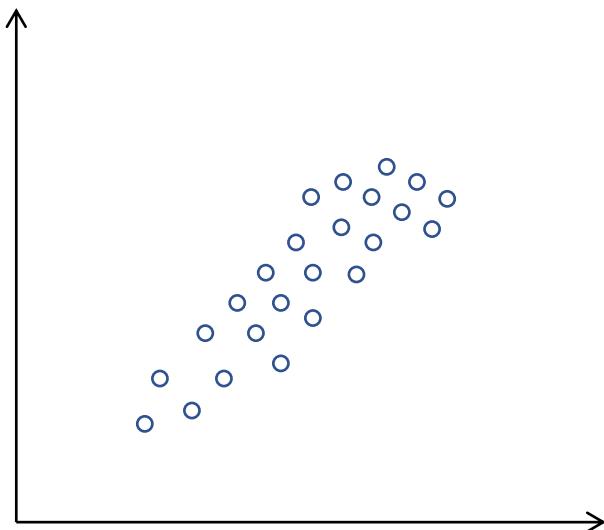
# 들어가며

Question 1)

데이터 집합이 다음과 같다.

어떤 것이 더 나은 표현인가?

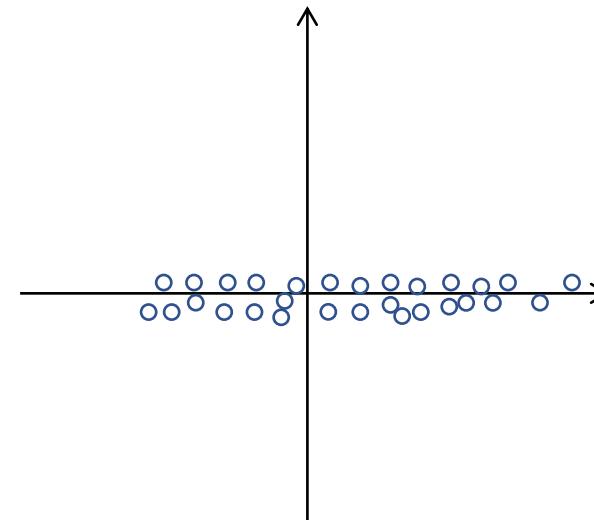
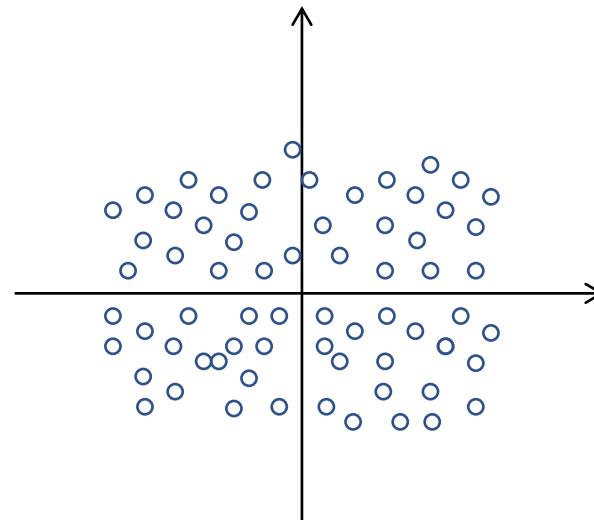
더 나은 표현이라는 것은 무슨 의미인가?



# 들어가며

Question 2)

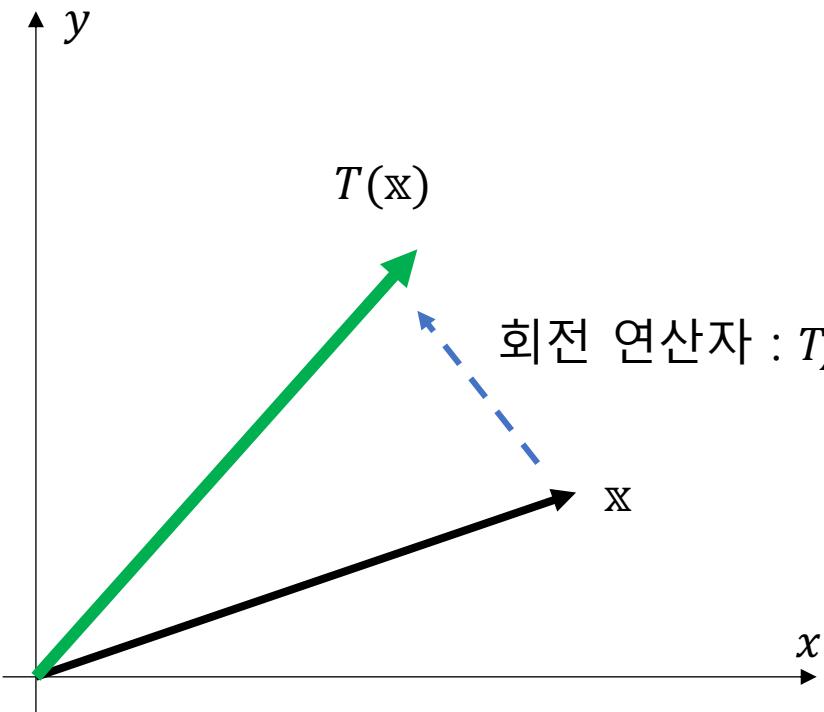
데이터 집합을 표현할 때,  $x$ 축  $y$ 축이 모두 필요한가?



# 다양한 선형변환

- $R^n \rightarrow R^m(R^n)$ 으로의 대표적인 선형변환
  - 회전변환
  - 반사변환
  - 사영변환

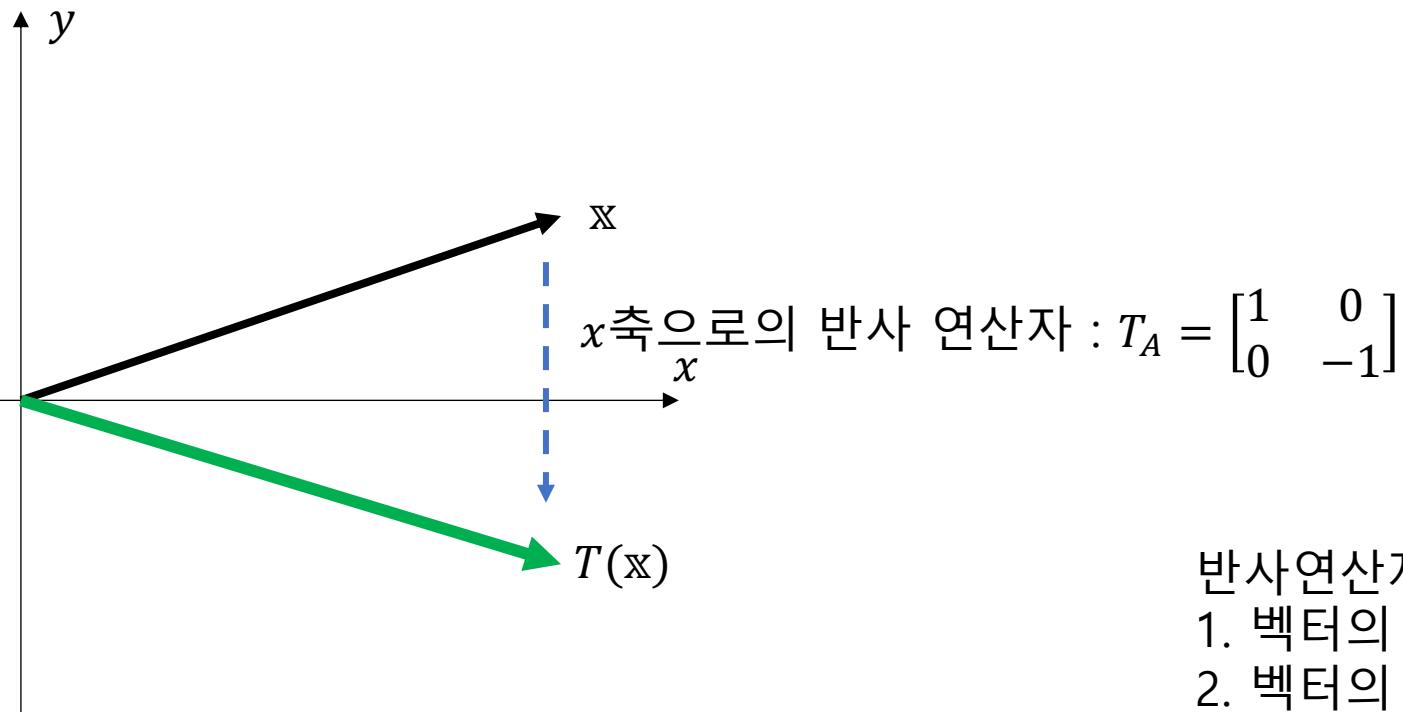
# $R^2 \rightarrow R^2$ 의 회전변환



회전 연산자 :  $T_A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$

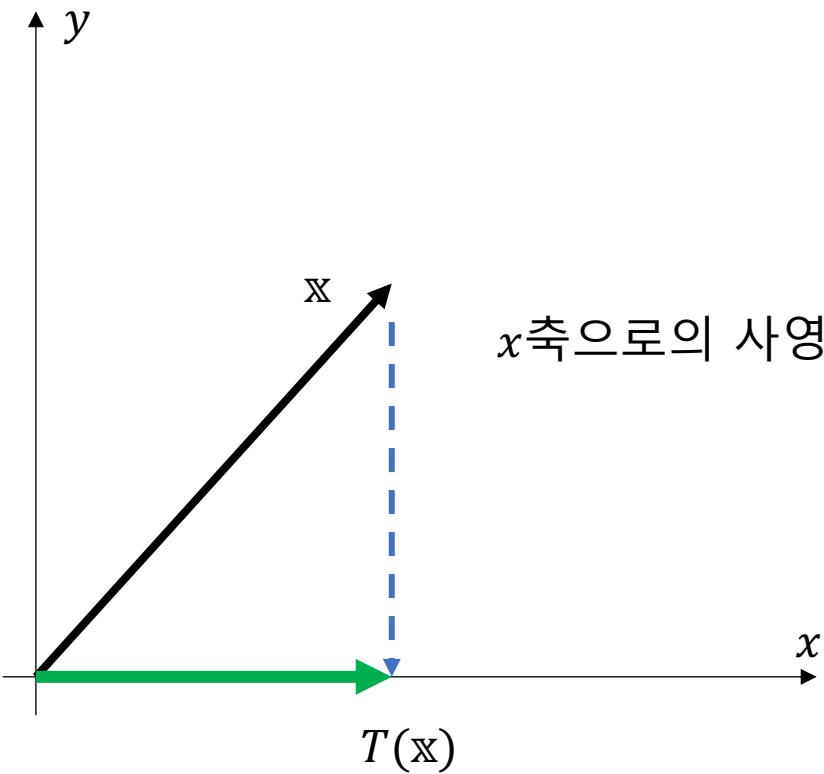
- 회전연산자의 특징
1. 벡터의 방향이 변한다.
  2. 벡터의 길이는 변하지 않는다.

# $R^2 \rightarrow R^2$ 의 반사변환



- 반사연산자의 특징
1. 벡터의 방향이 변한다.
  2. 벡터의 길이는 변하지 않는다.

# $R^2 \rightarrow R^2$ 의 사영변환



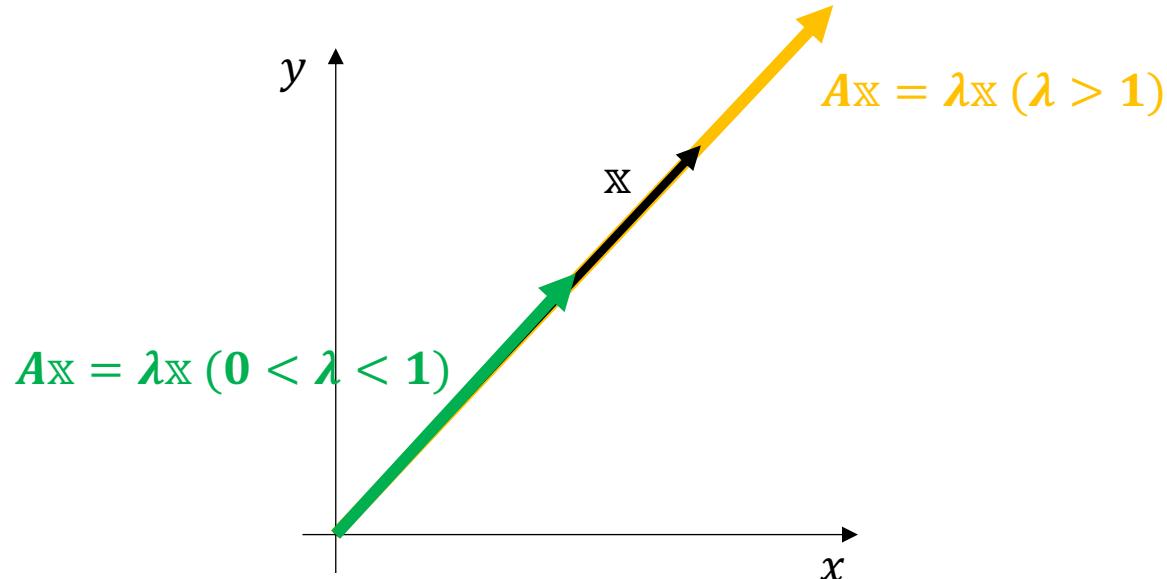
$x$ 축으로의 사영연산자 :  $T_A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$

- 회전연산자의 특징
1. 벡터의 방향이 변한다.
  2. 벡터의 길이도 변하다.

그러면 선형변환의 결과로 벡터의 방향은 바뀌지 않고, 벡터의 길이가 바뀌는 선형변환은 무엇이 있을까?

# 고유값과 고유벡터

- 정방행렬  $A$ 에 대하여, 스칼라(scala)인  $\lambda$ 와 영이 아닌 벡터  $v$ 에 대해  $Av = \lambda v$ 를 만족하는 경우,  $\lambda$ 는  $A$ 의 고유값(eigenvalue),  $v$ 는 대응하는 고유벡터(eigenvector)라고 한다.
- $\lambda$ 가 행렬  $A$ 의 고유값이면, 대응하는 고유벡터는 무수히 많다.
- 집합  $\{v : Av = \lambda v\}$ 는 벡터공간이며 고유값  $\lambda$ 에 대응하는 고유공간(eigenspace)이라 한다.



# 고유값과 고유벡터 예제

- $A = \begin{bmatrix} 4 & 0 & 1 \\ 2 & 3 & 2 \\ 1 & 0 & 4 \end{bmatrix}$ 의 고유값 중 하나는  $\lambda = 5$ 이고, 이에 대응하는 고유벡터  $\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$ 이다.
- $A = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & 1 & 2 \end{bmatrix}$ 의 고유값 중 하나는  $\lambda = 0$ 이고, 이에 대응하는 고유벡터  $\mathbf{x} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ 이다.
- $A$  를 대각행렬이라고 하자.  $A = diag(\lambda_1, \dots, \lambda_n)$  의 고유벡터와 고유값은? 표준 기저 벡터  $\mathbf{e}_1, \dots, \mathbf{e}_n$  는 고유벡터이고, 대각원소인  $\lambda_1, \dots, \lambda_n$  은 고유값이다.

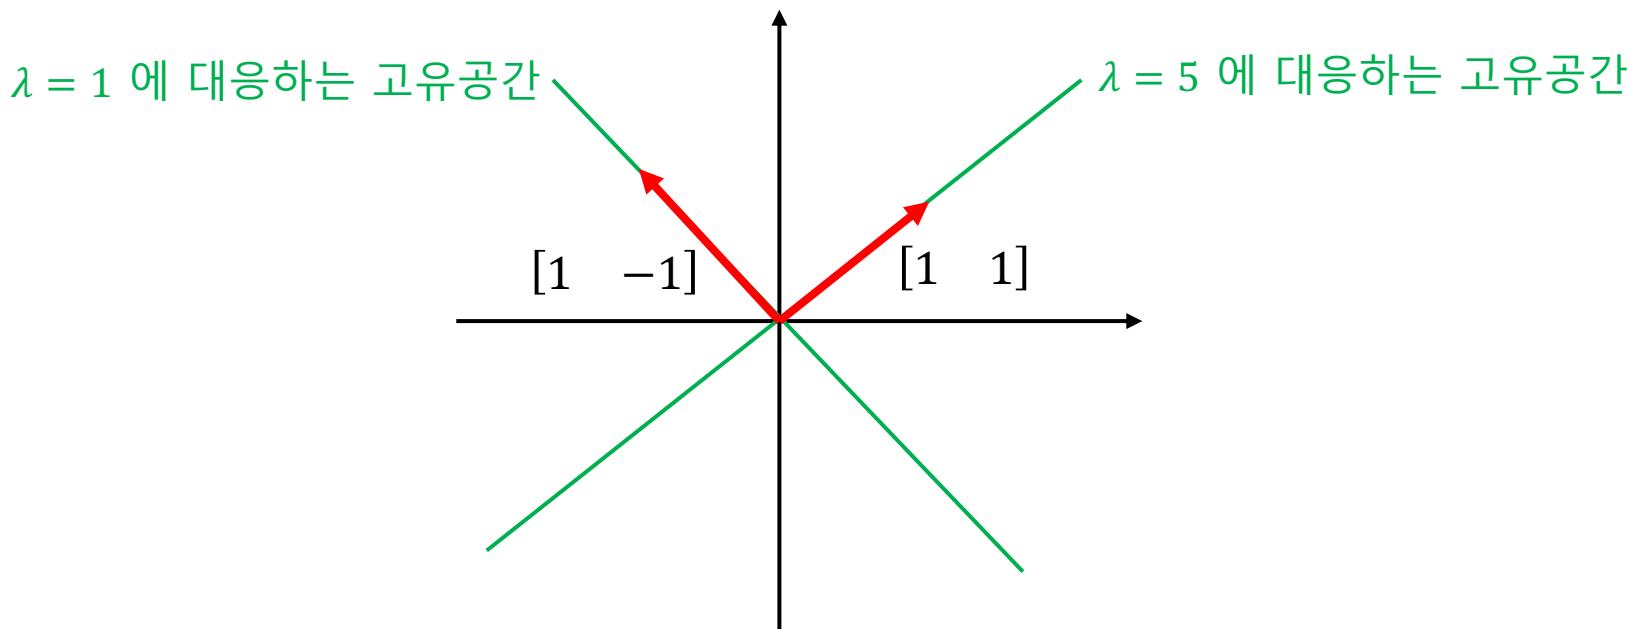
# 고유값과 고유벡터의 계산

행렬  $A$  의 고유값을  $\lambda$  , 대응하는 고유벡터를  $v$  라고 하자.

- $Av = \lambda v \rightarrow (A - \lambda I_n)v = \emptyset$  즉, 특성방정식  $\det(A - \lambda I_n) = 0$  을 만족시키는  $\lambda$  를 구하면 된다.
  - $2 \times 2$  의 경우는  $\det(A - \lambda I_2) = \lambda^2 - \text{tr}(A)\lambda + \det(A) = 0$  을 만족시켜주는  $\lambda$  를 구하면 된다.
- 행렬  $A = \begin{bmatrix} 1 & 3 \\ 4 & 2 \end{bmatrix}$  의 고유값과 그에 대응하는 고유벡터?

# 고유벡터 예제

- 행렬  $A = \begin{bmatrix} 3 & 2 \\ 2 & 3 \end{bmatrix}$  의 고유값과, 그에 대응하는 고유벡터를 구하여라. 그리고 고유공간을 그래프로 그려라.
  - $tr(A) = 6$ ,  $\det(A) = 5$  이므로  $\lambda^2 - 6\lambda + 5 = (\lambda - 1)(\lambda - 5) = 0$  을 만족시키는  $\lambda$ 의 값은 1, 5이다.



# 유사성

- 역행렬이 존재하는 행렬을 가역행렬이라고 한다.
- 가역행렬  $S$ 에 대해  $S^{-1}AS = B$ 가 만족되면 두 정방행렬  $A$ 와  $B$ 는 "유사 혹은 닮은(similar) 행렬"이라고 한다.
- 유사행렬(similar matrix)들은 동일한 고유값을 가진다.

# 대각화 가능성

- 만약 어떤 정방행렬  $A$  가 대각행렬  $D$  와 유사행렬이면, 즉 대각행렬  $D$  에 대해  $S^{-1}AS = D$ 를 만족하는 가역행렬  $S$ 가 있으면,  $A$ 는 "대각화 가능하다(diagonalizable)" 라고 한다.
- $n \times n$  행렬  $A$ 가 대각화 가능  $\Leftrightarrow A$ 가  $n$ 개의 일차독립인 고유벡터를 갖는 것
- $n$ 개의 일차독립인 고유벡터를 갖는  $n \times n$  행렬  $A$ 를 대각화하는 법
  - $A$  의  $n$  개의 일차독립인 고유벡터  $s_1, \dots, s_n$  을 구한다.
  - 행렬  $S = [s_1 \quad \cdots \quad s_n]$  을 구성한다.
  - 행렬  $S^{-1}AS$  는  $s_1, \dots, s_n$  에 각각 대응하는 고유값을 대각성분으로 하는 대각행렬이 될 것이다.

# 대각화 가능성 예제

행렬  $A = \begin{bmatrix} 0 & 0 & -2 \\ 1 & 2 & 1 \\ 1 & 0 & 3 \end{bmatrix}$  은 고유값  $\lambda = 1, \lambda = 2$  를 갖는다.

$\lambda = 1$  에 대응하는 고유공간의 기저벡터는  $s_1 = \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix}$

$\lambda = 2$  에 대응하는 고유공간의 기저벡터는  $s_2 = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}, s_3 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$  이다.

3개의 기저벡터는 일차독립이므로  $A$  는 대각화 가능하고  $S = \begin{bmatrix} -2 & -1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$

$S^{-1}AS = \begin{bmatrix} -1 & 0 & -1 \\ 1 & 0 & 2 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & -2 \\ 1 & 2 & 1 \\ 1 & 0 & 3 \end{bmatrix} \begin{bmatrix} -2 & -1 & 0 \\ 1 & 0 & 2 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix} = D$  로 대각화 된다.

# 대각화 가능과 고유값 사이의 관계

- 먼저, 대각행렬  $D = diag(\lambda_1, \dots, \lambda_n)$  의 행렬의 고유값은  $\lambda_1, \dots, \lambda_n$  이다. 행렬  $A$  와  $D$  가 유사행렬이라고 하자. 즉, 가역행렬  $S$  에 대하여,  $S^{-1}AS = D$  라고 하자. 그리고  $D$  가 대각행렬이므로,  $A$ 는 대각화 가능하다.  $A$ 의 고유값은  $D$ 의 고유값, 즉  $D$ 의 대각원소들이다. 그리고  $S$ 의 열들은 일차독립이며  $A$ 의 고유벡터들이 된다.

# 직교대각화 가능

- 정사각행렬  $S$ 에 대하여,  $S^T = S^{-1}$ 인 경우,  $A$ 를 **직교행렬**이라고 한다.
- 정사각행렬  $A$ 에 대해서,  $D = S^T AS$ 를 만족하는 대각행렬  $D$ 와, 직교행렬  $S$ 가 존재하면  $A$ 는 **직교대각화 가능**(orthogonally diagonalizable) 하다고 한다.
- 정사각행렬  $A$  가 직교대각화 가능  $\Leftrightarrow$  정사각행렬  $A$  가 대칭행렬

# 행렬의 인수분해

정수는 인수분해된다. 예를들어  $12 = 3 \times 4$ 처럼, 12는 3과 4로 인수분해된다.

마찬가지로 행렬도  $A = BC$ 처럼 인수분해 될 수 있다.

예를들어,  $\begin{bmatrix} 2 & 6 & 2 \\ -3 & -8 & 0 \\ 4 & 9 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 \\ -3 & 1 & 0 \\ 4 & -3 & 7 \end{bmatrix} \begin{bmatrix} 1 & 3 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix}$  이렇게 인수분해 될 수 있다.

행렬  $A$ 를 인수분해하여, 행렬  $A$ 와 가장 비슷하고(similar), 크기가 작은 행렬을  $A$ 대신 사용하려고 한다.

# 여러가지 행렬의 인수분해

- LU 분해 (LU Decomposition)
- 스펙트럼 분해 (Spectrum Decomposition) or 고유값 분해
- 특이값 분해 (Singular Value Decomposition)

# LU 분해

- LU분해는 행렬을 아래의 두 행렬로 인수분해한다.
  - 하부삼각행렬(행렬의 대각선의 윗부분이 모두 0)
  - 상부삼각행렬(행렬의 대각선의 아랫부분이 모두 0)

$$A = \begin{matrix} & \text{하부삼각행렬} \\ \begin{pmatrix} & & & \\ & 0 & & \\ & & 0 & \\ & & & 0 \end{pmatrix} & \times \\ & (\text{Lower Triangular Matrix}) & \end{matrix} \quad \begin{matrix} & \text{상부삼각행렬} \\ \begin{pmatrix} & & & 0 \\ & & & & \\ & & & & \\ & & & & \end{pmatrix} & \times \\ & (\text{Upper Triangular Matrix}) & \end{matrix}$$

- LU분해를 통하여 Linear Systems 문제를 간단하게 해결할 수 있다.

# LU 분해 예제

- $\begin{bmatrix} 2 & 6 & 2 \\ -3 & -8 & 0 \\ 4 & 9 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 3 \end{bmatrix}$  를 쉽게 풀어보자!

하부삼각행렬      상부삼각행렬

$$\begin{bmatrix} 2 & 6 & 2 \\ -3 & -8 & 0 \\ 4 & 9 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 \\ -3 & 1 & 0 \\ 4 & -3 & 7 \end{bmatrix} \begin{bmatrix} 1 & 3 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix}$$
 처럼 삼각행렬의 곱으로 이루어진다.

$$\begin{bmatrix} 2 & 0 & 0 \\ -3 & 1 & 0 \\ 4 & -3 & 7 \end{bmatrix} \begin{bmatrix} 1 & 3 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 3 \end{bmatrix}$$
 처럼 풀고자하는 식을 다시 쓸 수 있다.

먼저,  $\begin{bmatrix} 1 & 3 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$  으로 정의하자.

# LU 분해 예제

그러면 우리가 풀고자 하는 식은,  $\begin{bmatrix} 2 & 0 & 0 \\ -3 & 1 & 0 \\ 4 & -3 & 7 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 3 \end{bmatrix}$  으로 다시 쓸 수 있다.

즉,  $2y_1 = 2$ ,  $-3y_1 + y_2 = 2$ ,  $4y_1 - 3y_2 + 7y_3 = 3$  을 풀면 된다. 즉  $y_1 = 1$ ,  $y_2 = 5$ ,  $y_3 = 2$  가 된다.

식을 다시 써 보면,  $\begin{bmatrix} 1 & 3 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \\ 2 \end{bmatrix}$  가 된다.

즉,  $x_1 + 3x_2 + x_3 = 1$ ,  $x_2 + 3x_3 = 5$ ,  $x_3 = 2$  을 풀면 된다. 즉  $x_1 = 2$ ,  $x_2 = -1$ ,  $x_3 = 2$  가 된다.

이 예제는 행렬  $A$ 를 하부삼각행렬, 상부삼각행렬로 인수분해하면, 선형계  $A\mathbf{x} = \mathbf{b}$  는 풀이과정이 쉬워진다는 것을 명확히 보여주고 있다.

# LU 분해

- 정사각행렬  $A$ 가 하부삼각행렬  $L$ 과 상부삼각행렬  $U$ 의 곱  $A = LU$ 로 되는 인수분해를 LU 분해 또는 LU 인수분해(LU factorization)라고 부른다.
- 일반적으로 모든 정사각행렬  $A$ 가 LU 분해를 갖지 않으며, LU 분해가 존재하여도 LU 분해가 유일하지도 않다.

# 스펙트럼 분해

- 행렬  $A$ 가  $S = [\mathbf{s}_1 \ \cdots \ \mathbf{s}_n]$ 로 직교대각화되는 대칭행렬이고,  $\lambda_1, \dots, \lambda_n$ 은 각각  $\mathbf{s}_1, \dots, \mathbf{s}_n$ 에 대응하는  $A$ 의 고유값이라고 하면, 행렬  $D = S^T A S$ 는 대각성분이  $A$ 의 고유값인 대각행렬이 된다.

$$\bullet A = SDS^T = [\mathbf{s}_1 \ \cdots \ \mathbf{s}_n] \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{s}_1^T \\ \vdots \\ \mathbf{s}_n^T \end{bmatrix} = \lambda_1 \mathbf{s}_1 \mathbf{s}_1^T + \cdots + \lambda_n \mathbf{s}_n \mathbf{s}_n^T \text{ 와 같이 표현 가능하다.}$$

- 이 공식을  $A$ 의 스펙트럼 분해(spectral decomposition) 또는  $A$ 의 고유값 분해(eigenvalue decomposition)라고 한다.

# 특이값 분해

- SVD는 모든(any) 행렬에 대하여 적용가능한 분해(정수와 비교하면 인수분해) 기법이기 때문에, 행렬의 분해에 가장 널리 사용되는 기법이다.
- $n \times n$  행렬  $A$  가 대칭행렬이 아니면, 고유값 분해는 존재하지 않는다. 일반적인 경우에 대한 행렬의 인수분해를 위해서 특이값 분해(Singular Value Decomposition)를 사용한다.
- 디지털화된 정보의 압축, 저장, 전송에 활용

# 특이값 분해

- 행렬  $A$ 가 계수  $k$ 인  $m \times n$  행렬일 때,  $\textcolor{red}{A} = U\Sigma V^T$ 로 인수분해된다.

$$A = U\Sigma V^T = [\mathbb{U}_1 \quad \cdots \quad \mathbb{U}_k \quad | \quad \mathbb{U}_{k+1} \quad \cdots \quad \mathbb{U}_m] \begin{bmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_k \\ \hline O_{(m-k) \times k} & & O_{(m-k) \times (n-k)} \end{bmatrix} \begin{bmatrix} \mathbb{V}_1^T \\ \vdots \\ \mathbb{V}_k^T \\ - \\ \mathbb{V}_{k+1}^T \\ \vdots \\ \mathbb{V}_n^T \end{bmatrix}$$

- $U : m \times m$ ,  $\Sigma : m \times n$ ,  $V : n \times n$
- $V = [\mathbb{V}_1 \quad \cdots \quad \mathbb{V}_n]$  는  $A^T A$  를 직교대각화한다. 즉,  $\textcolor{red}{V}$ 의 컬럼은  $A^T A$ 의 고유벡터들이다.  $\mathbb{V}_i$ 는 orthonormal.
- $\lambda_1, \dots, \lambda_k$  가  $V$ 의 열벡터에 대응하는  $A^T A$ 의 영이 아닌 고유값일 때,  $\Sigma$ 의 영이 아닌 대각성분은  $\sigma_1 = \sqrt{\lambda_1}, \dots, \sigma_k = \sqrt{\lambda_k}$  이다. 이 대각성분들을 **특이값(singular value)**이라고 한다.  $k$ 는  $A$ 의 계수이다.
- $V$ 의 열벡터는  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_k > 0$  을 만족시키도록 배열되어 있다.
- $\{\mathbb{U}_1, \dots, \mathbb{U}_k\}$  는  $\text{col}(A)$ 의 정규직교기저이다.  $\mathbb{U}_i$ 는 orthonormal.

# $A^T A$ , $AA^T$

- $A^T A$  (임의의 행렬  $A$ )
  - $A^T A = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T \Sigma)V^T = VDV^T$ 
    - $D = \Sigma^T \Sigma$  이기 때문에  $D$ 의 대각성분은 singular value의 제곱
  - $(A^T A)V = VDV^T V = VD$
  - 위의 식에 의하여  $A^T A$ 의 고유값은  $V$ 의 대각성분들이 되고,  $V$ 의 columns은  $A^T A$ 의 고유벡터가 된다.
- $AA^T$  (임의의 행렬  $A$ )
  - $AA^T = U\Sigma V^T V\Sigma^T U^T = U\Sigma^T \Sigma U^T = UDU^T$ 
    - $D = \Sigma^T \Sigma$  이기 때문에  $D$ 의 대각성분은 singular value의 제곱
  - $(AA^T)U = UDU^T U = UD$
  - 위의 식에 의하여  $AA^T$ 의 고유값은  $U$ 의 대각성분들이 되고,  $U$ 의 columns은  $AA^T$ 의 고유벡터가 된다.
- $A^T A$ 의 eigenvector는 PCA에서의,  $A$ 의 공분산 행렬의 주성분이다.

# 특이값 분해 예제

- 행렬  $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$  의 특이값분해를 구하라.

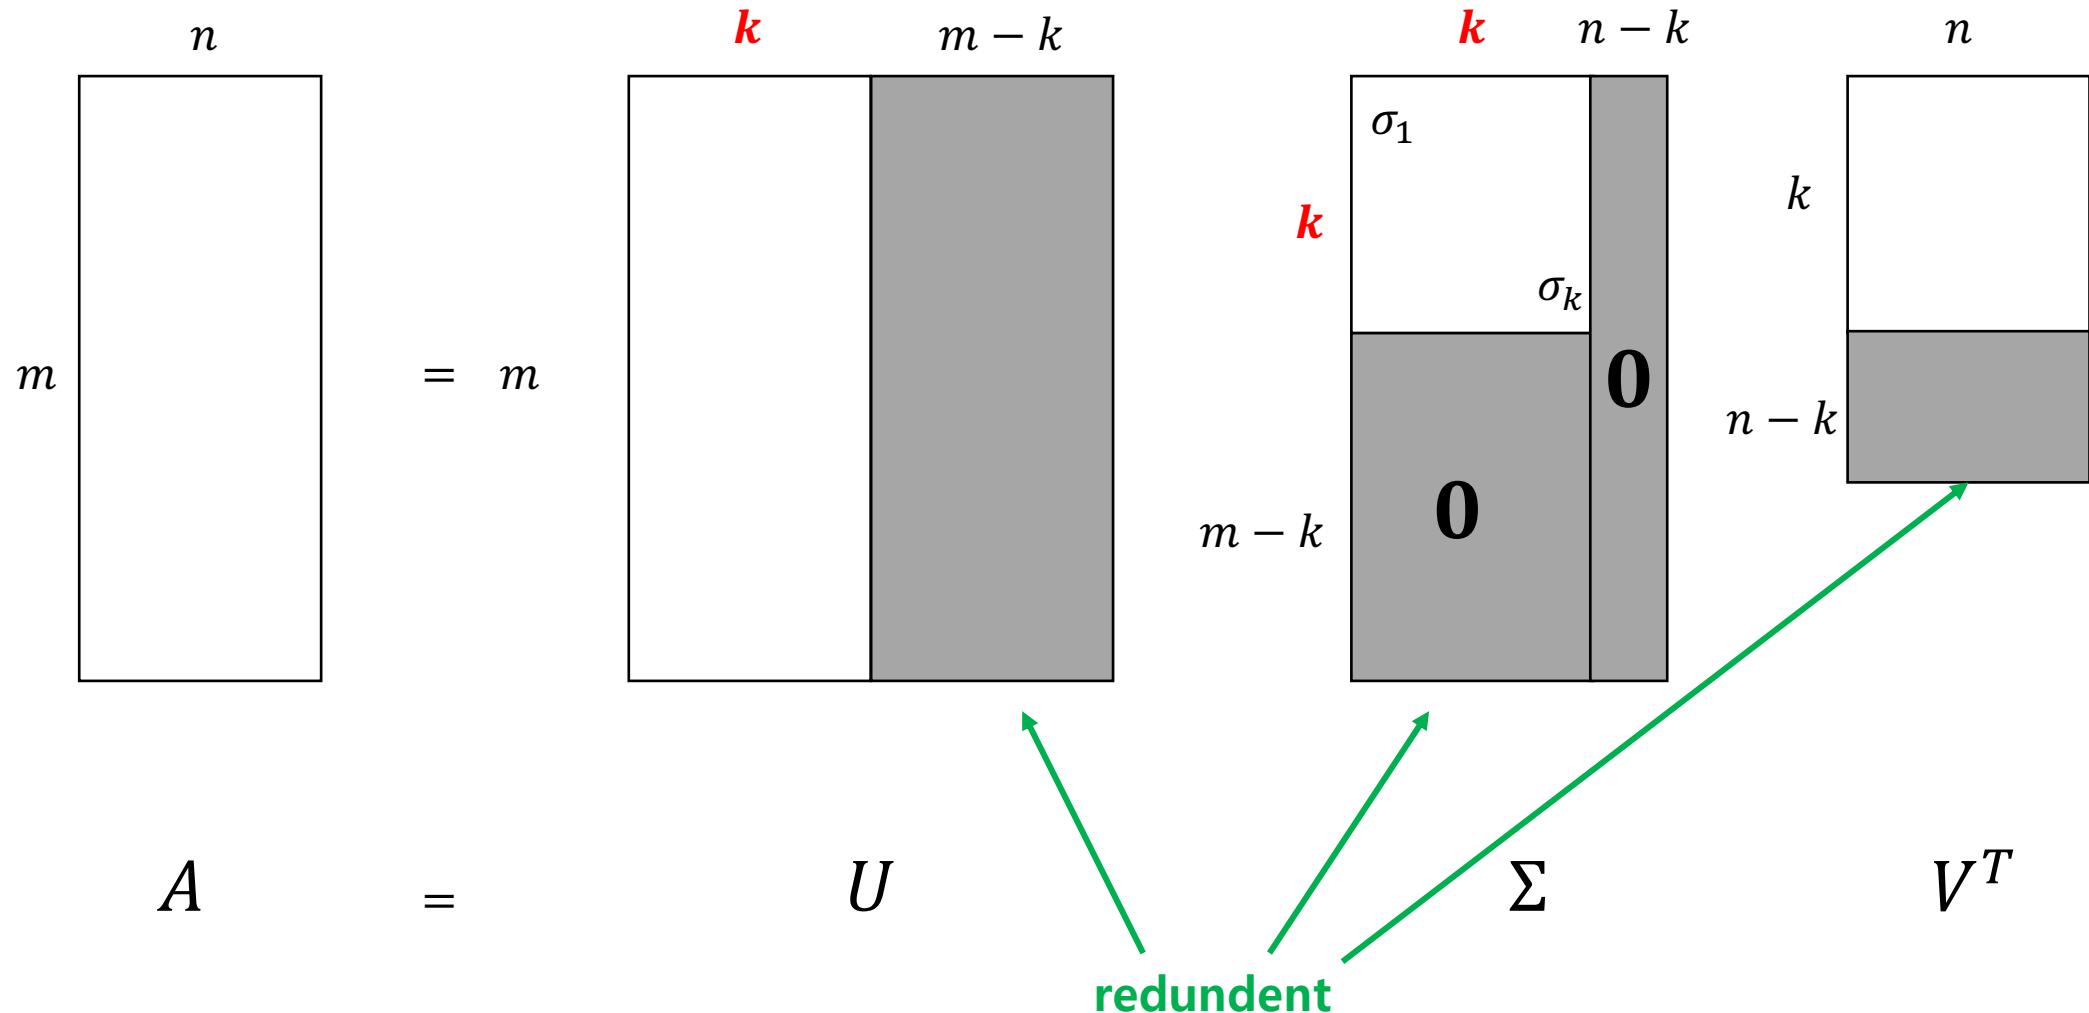
- $A^T A$  의 고유값을 구한다.  $\lambda_1 = 3, \lambda_2 = 1$
- 특이값을 구한다.  $\sigma_1 = \sqrt{\lambda_1} = \sqrt{3}, \sigma_2 = \sqrt{\lambda_2} = \sqrt{1}$
- $A^T A$  의 고유벡터를 구한다.  $(v_1, \dots, v_n)$
- $\frac{1}{\sigma_i} A v_i = u_i$  를 구한다.  $(u_1, \dots, u_m)$

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$$

$$= U \Sigma V^T$$

$$= \begin{bmatrix} \frac{\sqrt{6}}{3} & 0 & -\frac{1}{\sqrt{3}} \\ \frac{\sqrt{6}}{6} & -\frac{\sqrt{2}}{2} & \frac{1}{\sqrt{3}} \\ \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & \frac{1}{\sqrt{3}} \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{bmatrix}$$

# 축소된 SVD



# 축소된 SVD

$$A = U_1 \Sigma_1 V_1^T$$

The diagram illustrates the decomposition of matrix  $A$  into three components. Matrix  $A$  is shown as a rectangle with dimensions  $m$  (height) by  $n$  (width). It is equated to the product of three matrices:  $U_1$ ,  $\Sigma_1$ , and  $V_1^T$ . Matrix  $U_1$  is  $m$  by  $k$ , where  $k$  is indicated by a red  $k$  above it. Matrix  $\Sigma_1$  is a  $k$  by  $k$  diagonal matrix, represented by a rectangle containing the diagonal elements  $\sigma_1$  and  $\sigma_k$ , with a red  $k$  to its left. Matrix  $V_1^T$  is  $n$  by  $k$ , where  $n$  is indicated by a red  $n$  above it.

# 축소된 SVD

- 영블록을 인수로 하는 곱을 없애보자.

$$A = U\Sigma V^T = [\mathbb{U}_1 \quad \cdots \quad \mathbb{U}_k \quad | \quad \mathbb{U}_{k+1} \quad \cdots \quad \mathbb{U}_m] \begin{bmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_k \\ \hline O_{(m-k) \times k} & & O_{(m-k) \times (n-k)} \end{bmatrix} \begin{bmatrix} \mathbb{V}_1^T \\ \vdots \\ \mathbb{V}_k^T \\ - \\ \mathbb{V}_{k+1}^T \\ \vdots \\ \mathbb{V}_n^T \end{bmatrix}$$



$$A = U_1 \Sigma_1 V_1^T = [\mathbb{U}_1 \quad \cdots \quad \mathbb{U}_k] \begin{bmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_k \end{bmatrix} \begin{bmatrix} \mathbb{V}_1^T \\ \vdots \\ \mathbb{V}_k^T \end{bmatrix}$$

- $U_1 : m \times k$ ,  $\Sigma_1 : k \times k$ ,  $V_1^T : k \times n$

# 축소된 SVD

- $A$  의 축소된 특이값 확장(reduced singular expansion)

$$\bullet A = U_1 \Sigma_1 V_1^T = [\mathbb{U}_1 \quad \cdots \quad \mathbb{U}_k] \begin{bmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_k \end{bmatrix} \begin{bmatrix} \mathbb{V}_1^T \\ \vdots \\ \mathbb{V}_k^T \end{bmatrix} = \sigma_1 \mathbb{U}_1 \mathbb{V}_1^T + \cdots + \sigma_k \mathbb{U}_k \mathbb{V}_k^T$$

- 이 결과는 모든 행렬에 적용된다.

# 축소된 SVD 예제

- 행렬  $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$  의 축소된 특이값분해를 구하라.

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$$

$$= U_1 \Sigma V_1^T$$

$$= \begin{bmatrix} \frac{\sqrt{6}}{3} & 0 \\ \frac{\sqrt{6}}{6} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{bmatrix}$$

# LSA (Latent Semantic Analysis)

- LSA(LSI)는 document data의 숨겨진 의미(hidden concept)를 찾아내는 기법이다.
- LSA는 각각의 문서(document)와 단어(word)를 벡터로 표현한다. 벡터내에서 각각의 element는 **숨겨진 의미**가 될 것이다.

# LSA (Latent Semantic Analysis)

$d_1$  : *Romeo and Juliet.*

$d_2$  : *Juliet: O happy dagger!*

$d_3$  : *Romeo died by dagger.*

$d_4$  : *"Live free or die", that's the New-Hampshire's motto.*

$d_5$  : *Did you know, New-Hampshire is in New-England.*

query :

- dies
- dagger

- 3번 문서는 쿼리에 대해서 1등이 될 것이다.
- 2번, 4번 문서는 그 다음이 될 것이다.
- 1번, 5번 문서는?
  - ✓ 사람들이 인식하기로는 문서 1번이 문서 5번 보다 주어진 쿼리에 더 맞는 문서이다.

**컴퓨터도 이러한 추론 과정을 할 수 있을까? 즉 숨겨진 의미를 찾을 수 있을까?**

# LSA (Latent Semantic Analysis)

**matrix A :**

	$d_1$	$d_2$	$d_3$	$d_4$	$d_5$
<i>romeo</i>	1	0	1	0	0
<i>juliet</i>	1	1	0	0	0
<i>happy</i>	0	1	0	0	0
<i>dagger</i>	0	1	1	0	0
<i>live</i>	0	0	0	1	0
<i>die</i>	0	0	1	1	0
<i>free</i>	0	0	0	1	0
<i>new-hampshire</i>	0	0	0	1	1

**matrix B** =  $A^T A$  doc-doc matrix

즉, 문서  $i$ 와 문서  $j$ 가  $b$ 개의 단어를 가지고 있으면  $B[i,j] = b$

**matrix C** =  $AA^T$  term-term matrix

즉, 단어  $i$ 와 단어  $j$ 가  $c$  문서에서 함께 발생했으면  $C[i,j] = c$

# LSA (Latent Semantic Analysis)

SVD 사용!

$A = S\Sigma U^T$ ,  $S$ 는  $B$ 의 eigenvector이고,  $U$ 는  $C$ 의 eigenvector이다.

$$\Sigma = \begin{bmatrix} 2.285 & 0 & 0 & 0 & 0 \\ 0 & 2.010 & 0 & 0 & 0 \\ 0 & 0 & 1.361 & 0 & 0 \\ 0 & 0 & 0 & 1.118 & 0 \\ 0 & 0 & 0 & 0 & 0.797 \end{bmatrix}$$

 singular value

# LSA (Latent Semantic Analysis)

**Reduced SVD 사용!**

$A_k = S_k \Sigma_k U_k^T$ , 모든 singular value를 사용할 수 없고, 작은 것들은 제외한다.

$k$ 개의 특이값만 남기는 것이다. 즉  $k$ 개의 "hidden concepts"만 남긴다.

# LSA (Latent Semantic Analysis)

$$\Sigma_2 = \begin{bmatrix} 2.285 & 0 \\ 0 & 2.010 \end{bmatrix}$$

$$U_2^T = \begin{bmatrix} -0.311 & -0.407 & -0.594 & -0.603 & -0.143 \\ 0.363 & 0.541 & 0.200 & -0.695 & -0.229 \end{bmatrix}$$

$$S_2 = \begin{bmatrix} romeo & -0.396 & 0.280 \\ juliet & -0.314 & 0.450 \\ happy & -0.178 & 0.269 \\ dagger & -0.438 & 0.369 \\ live & -0.264 & -0.346 \\ die & -0.524 & -0.246 \\ free & -0.264 & -0.346 \\ new-hampshire & -0.326 & -0.460 \end{bmatrix}$$

# LSA (Latent Semantic Analysis)

$$S_2 \Sigma_2$$
$$\text{romeo} = \begin{bmatrix} -0.905 \\ 0.563 \end{bmatrix}, \text{juliet} = \begin{bmatrix} -0.717 \\ 0.905 \end{bmatrix}, \text{happy} = \begin{bmatrix} -0.407 \\ 0.541 \end{bmatrix}, \text{dagger} = \begin{bmatrix} -1.001 \\ 0.742 \end{bmatrix},$$

$$\text{live} = \begin{bmatrix} -0.603 \\ -0.695 \end{bmatrix}, \text{die} = \begin{bmatrix} -1.197 \\ -0.494 \end{bmatrix}, \text{free} = \begin{bmatrix} -0.603 \\ -0.695 \end{bmatrix}, \text{new-hampshire} = \begin{bmatrix} -0.745 \\ -0.925 \end{bmatrix},$$

$$\Sigma_2 U_2^T$$
$$d_1 = \begin{bmatrix} -0.711 \\ 0.730 \end{bmatrix}, d_2 = \begin{bmatrix} -0.930 \\ 1.087 \end{bmatrix}, d_3 = \begin{bmatrix} -1.357 \\ 0.402 \end{bmatrix}, d_4 = \begin{bmatrix} -1.378 \\ -1.397 \end{bmatrix}, d_5 = \begin{bmatrix} -0.327 \\ -0.460 \end{bmatrix}.$$

$$q = \frac{\begin{bmatrix} -1.197 \\ -0.494 \end{bmatrix} + \begin{bmatrix} -1.001 \\ 0.742 \end{bmatrix}}{2} = \begin{bmatrix} -1.099 \\ 0.124 \end{bmatrix}$$

cosine similarity

$$\frac{d_i \cdot q}{|d_i||q|}$$

# LSA (Latent Semantic Analysis)

